



Projekttitel:

KI-Dokumentenassistent – Lokale Dokumentenanalyse und intelligente Wissenssuche mit Retrieval-Augmented Generation (RAG)

Datum:15.07.2026

Kursinformationen:

- **Kursname:** KI Anwendungen
 - **Kursanbieter:** educX GmbH
-

Teilnehmerinformationen:

- **Name:** Jaroslaw Urich
 - **E-Mail:** jaroslaw.urich@gmail.com
-

Projektzeitraum:

- **Projektstart:** 13.07.2026, 08:00 Uhr
 - **Projektende:** 17.07.2026, 16:00 Uhr
-

Projektzusammenfassung:

Entwicklung eines lokalen KI-Dokumentenassistenten zur automatischen Analyse und intelligenten Durchsuchung von Dokumenten. Hochgeladene Dateien werden verarbeitet, in einer Vektordatenbank gespeichert und mithilfe eines lokalen Sprachmodells beantwortet. Durch Retrieval-Augmented Generation (RAG) werden relevante Dokumentinhalte als Kontext für präzise Antworten genutzt. Die Anwendung läuft vollständig lokal mit Docker und Ollama.

Leitfaden für nachvollziehbare Schritte

1. Kurze Darstellung des Problembereichs / Aufriss des Themas

1.1 Inhaltlich

Kern der Untersuchung

Ziel des Projekts ist die Entwicklung eines lokalen KI-Dokumentenassistenten, der Dokumente automatisch verarbeitet und Fragen anhand der enthaltenen Informationen beantwortet. Dabei kommt das Verfahren **Retrieval-Augmented Generation (RAG)** zum Einsatz.

Grobziele der Arbeit

- Entwicklung eines lokalen KI-Assistenten
- Automatische Verarbeitung verschiedener Dokumentformate
- Aufbau einer Vektordatenbank
- Intelligente Dokumentensuche
- Chatbasierte Beantwortung von Fragen

1.2 Begründung des Themas

Unternehmen verwalten täglich große Mengen an Dokumenten. Die manuelle Suche nach relevanten Informationen ist zeitaufwendig und fehleranfällig. Moderne KI-Verfahren ermöglichen eine effiziente Analyse und intelligente Suche innerhalb dieser Dokumente.

Das Projekt zeigt, wie mit frei verfügbaren Open-Source-Technologien ein datenschutzfreundlicher Dokumentenassistent entwickelt werden kann, der vollständig lokal betrieben wird.

2. Nachvollziehbare Schritte

2.1 Stand der Forschung / Literatur / Tutorials

Für die Umsetzung wurden aktuelle Dokumentationen und Tutorials zu folgenden Technologien verwendet:

- LangChain
- LangGraph
- Ollama
- ChromaDB
- Streamlit
- Retrieval-Augmented Generation (RAG)
- Hybrid Retrieval (Embeddings + BM25)

Die Literatur zeigt, dass RAG-Systeme die Qualität von KI-Antworten verbessern, indem relevante Dokumentinhalte als Kontext bereitgestellt werden.

2.2 Fragestellung

Wie kann ein lokaler KI-Dokumentenassistent entwickelt werden, der Dokumente automatisiert analysiert und mithilfe von RAG präzise Antworten auf Benutzerfragen liefert?

2.3 Stand der Forschung

Aktuelle RAG-Systeme kombinieren Vektorsuche mit großen Sprachmodellen, um Halluzinationen zu reduzieren und Antworten auf Basis vorhandener Dokumente zu generieren. Moderne Frameworks wie LangChain und ChromaDB erleichtern die Umsetzung solcher Systeme.

2.4 Wissenslücke

Viele bestehende Lösungen basieren auf Cloud-Diensten und sind für sensible Unternehmensdaten nur eingeschränkt geeignet. Ziel dieses Projekts ist daher die Entwicklung einer vollständig lokal ausführbaren und datenschutzfreundlichen Lösung.

2.5 Methode

Das Projekt wurde schrittweise umgesetzt:

1. Einrichtung der Entwicklungsumgebung mit Docker und Python.

2. Entwicklung einer Streamlit-Oberfläche für Dokumentenupload und Chat.
3. Verarbeitung der Dokumente (PDF, TXT, Markdown und CSV).
4. Aufteilung der Dokumente in Textabschnitte (Chunking).
5. Erstellung von Embeddings mit **Nomic Embed Text**.
6. Speicherung der Embeddings in **ChromaDB**.
7. Implementierung einer hybriden Suche (ChromaDB + BM25).
8. Optionales Reranking der Suchergebnisse.
9. Übergabe des gefundenen Kontexts an **Llama 3.2** über Ollama.
10. Ausgabe der Antwort im Chat.

2.6 Ergebnisse

Es wurde ein funktionsfähiger KI-Dokumentenassistent entwickelt, der:

- Dokumente automatisch verarbeitet,
- Inhalte persistent speichert,
- relevante Informationen über Hybrid Retrieval findet,
- Fragen in natürlicher Sprache beantwortet,
- vollständig lokal und datenschutzfreundlich arbeitet.

2.7 Ausblick

Das System kann zukünftig erweitert werden durch:

- Unterstützung weiterer Dateiformate (Word, Excel, PowerPoint)
- OCR für gescannte PDFs
- Streaming-Antworten
- Mehrbenutzerbetrieb
- Quellenangaben in Antworten
- Websuche als zusätzliche Informationsquelle
- Optimierung des Rerankings und der Retrieval-Strategien

Damit bietet der entwickelte KI-Dokumentenassistent eine solide Grundlage für den Einsatz als internes Wissens- und Assistenzsystem in Unternehmen.