



Große Sprachmodelle (LLMs)

Von Wörtern zur Intelligenz



Was ein LLM wirklich ist

Datei 1: Die Gewichte (Parameters)

- ~140 GB für ein 70B-Modell (float16 = 2 Byte pro Parameter)
- Enthält das gesamte „Wissen“ — komprimiert aus riesigen Trainingsdaten
- Einmalig teuer zu erzeugen — danach frei nutzbar

Datei 2: Der Ausführungscode (Run File)

- ~500 Zeilen C — keine externen Abhängigkeiten
- Liest die Gewichte und berechnet das nächste Token
- Vollständig offline lauffähig — sogar auf einem Laptop


Was ein LLM wirklich ist

Training = Komprimierung des Internets

- Llama 2 70B: ~10 TB Text, ~6.000 GPUs, ~12 Tage, ~2 Mio. \$
- Frontier-Modelle: 100+ TB, 10.000–100.000+ GPUs, \$10–100 Mio.

Eine Aufgabe: das nächste Wort vorhersagen

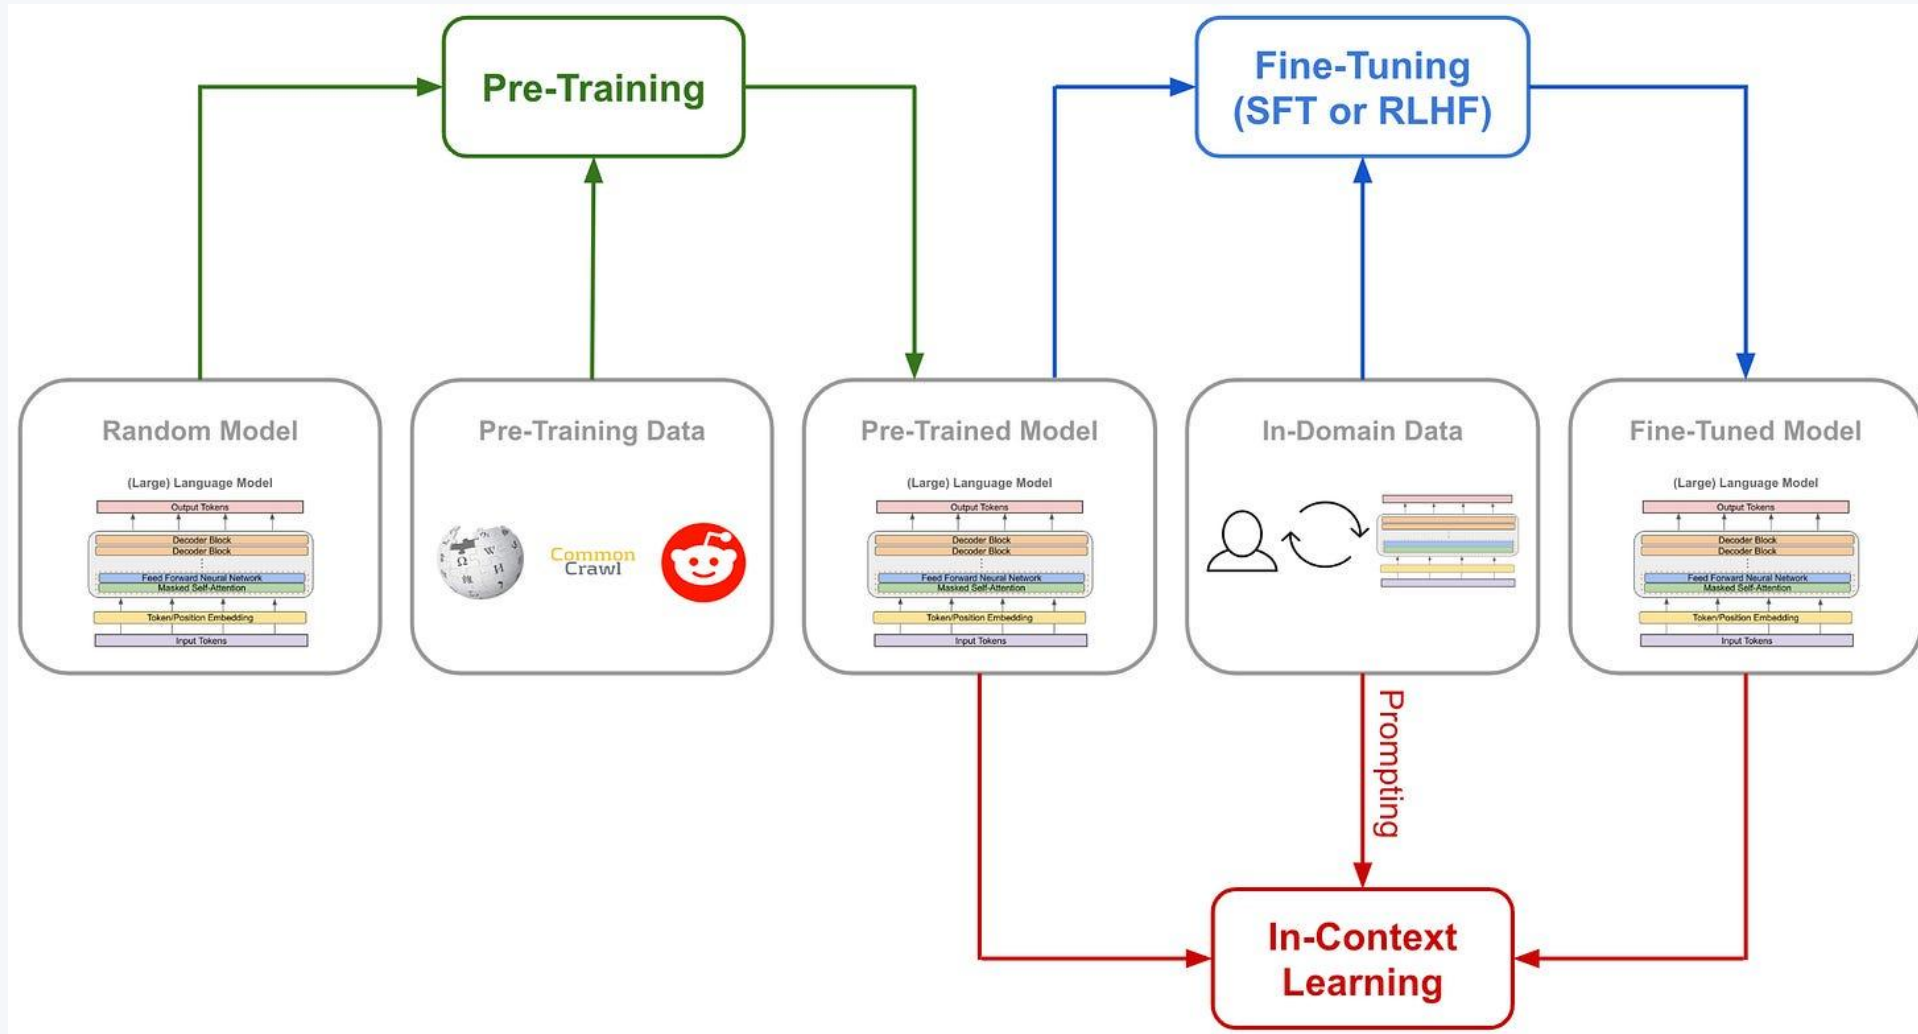
- Klingt trivial — ist es nicht: erfordert implizit enormes Weltwissen



Von der Architektur zum Produkt

Stufe	Ziel	Daten	Kosten
Vortraining	Sprache, Fakten und Logik aus dem Internet lernen	10–100+ TB, geringe Qualität	Millionen \$, Monate
Supervised Fine-Tuning (SFT)	Assistenzverhalten — Anweisungen befolgen lernen	~100K Instruktions-Antwort-Paare, hohe Qualität	Tausende \$, Tage
RLHF (optional)	Verbesserung durch menschliche Präferenzvergleiche	Vergleichslabels	Moderat
LoRA / PEFT	Domänen- und aufgabenspezifische Anpassung ohne vollständiges Neutraining	50K–500K qualitativ hochwertige Beispiele	Gering bis moderat

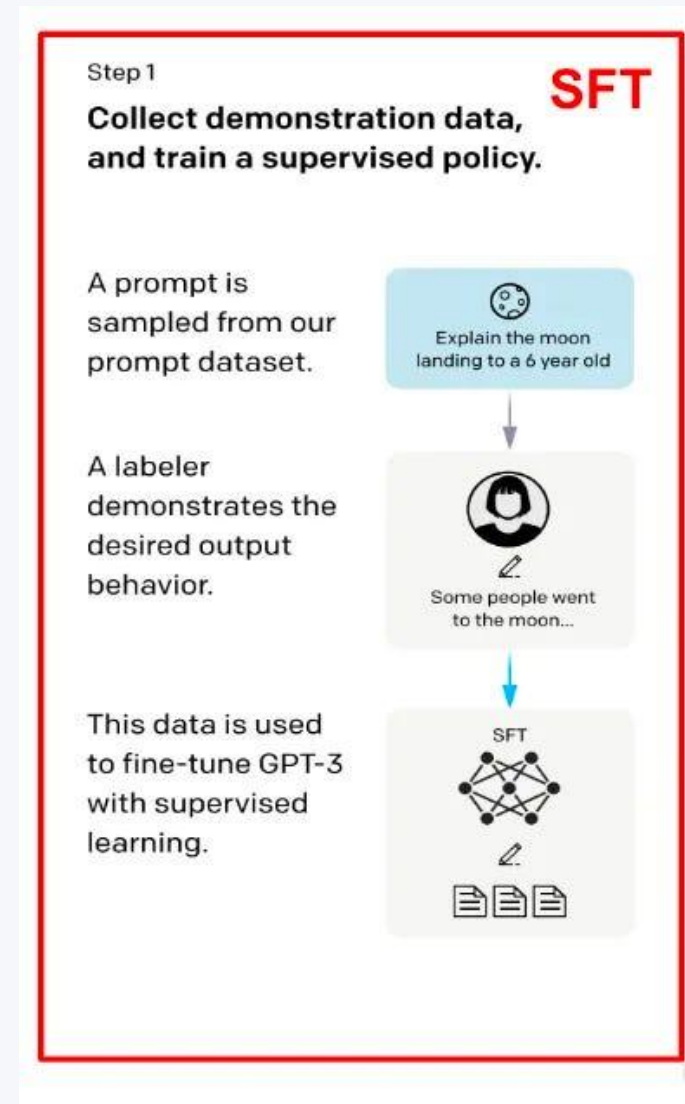
Von der Architektur zum Produkt



SFT — Supervised Fine-Tuning

SFT — Supervised Fine-Tuning

- Erste Feinabstimmungsphase nach dem Vortraining: Das Basismodell lernt, Anweisungen zu befolgen
- Training auf Demonstrations-Paaren: Prompt → Erwartete Antwort, erstellt von menschlichen Experten
- Verlustfunktion: Cross-Entropy — das Modell lernt, die Zieltokens Schritt für Schritt vorherzusagen
- Transformation: Vom reinen „nächsten Token vorhersagen“ zum „sinnvolle Anweisungen ausführen“





LoRA — Low-Rank Adaptation

LoRA — Parameter-effizientes Feinabstimmen

- Basismodell bleibt eingefroren — die ursprünglichen Gewichte W werden nicht verändert
- Stattdessen wird $\Delta W = A \times B$ additiv eingefügt (A und B sind kleine, niedrigrangige Matrizen)
- Rang $r \ll d$: Typischerweise $r = 8$ bis 64 — statt Milliarden trainierbare Parameter nur Millionen
- Reduziert trainierbare Parameter um bis zu 10.000-fach gegenüber Full Fine-Tuning

Vorteile in der Praxis

- Feinabstimmung auf einer Consumer-GPU möglich (z. B. 8 GB VRAM statt Hunderte GB)
- Mehrere spezialisierte LoRA-Adapter auf dasselbe Basismodell austauschbar einsetzbar
- Anwendungen: Domänenanpassung, Sprachspezialisierung, Stil-Feinabstimmung (z. B. Stable Diffusion)

RLHF — Feinabstimmungsstufe 3

Warum Vergleiche statt Antworten?

- Zwei Antworten zu vergleichen ist leichter als eine perfekte Antwort zu formulieren
- Labeler brauchen kein Expertenwissen — nur Urteilsvermögen beim Vergleich

Der RLHF-Prozess

- 1. Assistent generiert mehrere Kandidatenantworten zu einer Frage
- 2. Menschliche Labeler ranken/vergleichen die Kandidaten
- 3. Vergleiche trainieren ein Belohnungsmodell (Reward Model)
- 4. LM wird via Reinforcement Learning optimiert, um den Belohnungswert zu maximieren

