


The background is a dark blue gradient filled with intricate white and light blue circuit-like patterns. These patterns include straight lines, circles, and branching structures, reminiscent of a neural network or a complex circuit board. In the center, there is a glowing, semi-transparent brain shape. The brain is composed of various circular and circular-like elements, some of which are highlighted with a bright blue glow. A horizontal white rectangular bar is positioned across the middle of the image, serving as a backdrop for the text.

Prompt Engineering

Wie denkt ein LLM?

Transformer-Modell


- Arbeitet tokenbasiert: es sagt auf Basis von Wahrscheinlichkeiten voraus, welches Token als Nächstes am besten passt.
- Basierend auf riesigen Datenmengen und Wahrscheinlichkeiten

Instruction Tuning

- LLMs wurden darauf trainiert, auf Anweisungen (Prompts) zu reagieren
- Reaktion basiert auf statistisch gelernten Mustern aus ähnlichen Anfragen

Kein echtes „Verstehen“

- Ein LLM „versteht“ Inhalte nicht wie ein Mensch.
- Es erkennt sprachliche Muster und erzeugt daraus wahrscheinliche Antworten.



Sampling controls

AI Creativity controls

Temperature Creativity Dial



The cat sat on the...

Low Temperature
More predictable

High Temperature
More Creative

The cat sat on the mat

The cat sat on the moonlit balcony.



Top-K Word Limit



K=3

top 3 most likely words at each step

The cat sat on the mat, chair, or windowsill.

Ignore "piano" or "rainbow"



Top-P Probability Threshold



P=0.8

Smallest group of words whose probability adds to 80%

The cat sat on the mat, chair, porch or windowsill.

Ignore "piano" or "rainbow"



↓ Temp ↑ Top-P

Less creative, Strike a balance of common and less common words

↑ Temp ↓ Top-P

maximize surprise and creativity by selecting unusual words

The cat sat on the fluffy mat



The cat sat on the moonlit balcony



@pvergadia

Follow for more!


Sampling controls

Temperature

- Reguliert die Zufälligkeit der Token-Auswahl global.
- Stellt die „Kreativität“ ein: niedrig = vorhersehbar, hoch = kreativ und riskanter.
- Es verändert die Wahrscheinlichkeiten aller Wörter, aber schränkt das Vokabular nicht ein.
- Temperatur 0 entspricht dem immer besten Token (greedy decoding).

Top-K Sampling


- Das Modell schaut auf alle möglichen nächsten Tokens, behält nur die K wahrscheinlichsten (z.B. 40) und ignoriert den Rest.
- Kleinere K macht die Ausgabe fokussierter, größere K erlaubt mehr Variation.
- Wird oft verwendet, um sehr seltene Tokens zu vermeiden.



Sampling controls

Top-P Sampling (Nucleus Sampling)

- Statt einer festen Anzahl nimmt Top-P alle Wörter, bis z.B. 90 % der Gesamtwahrscheinlichkeit erreicht sind.
- Die Anzahl der berücksichtigten Tokens variiert je nach Verteilung der Wahrscheinlichkeiten.
- Wenn das Modell sehr sicher ist, sind das nur wenige Wörter; wenn es unsicher ist, werden automatisch mehr zugelassen.
- Bietet eine adaptive Balance zwischen Vielfalt und Kohärenz.
- Flexibler als Top-K, da die Poolgröße sich an die Sicherheit des Modells anpasst.



Prompt Engineering


- Prompt Engineering bedeutet, Eingaben so zu formulieren, dass ein KI-Modell möglichst passende, präzise und nützliche Antworten erzeugt.
- Da LLMs keine Absichten verstehen, ist die Formulierung des Prompts entscheidend für das Ergebnis.
- Ein guter Prompt beeinflusst Inhalt, Stil, Format, Genauigkeit und Detailtiefe der Antwort.
- Prompt Engineering ist deshalb weniger Programmierung als klare Kommunikation mit dem Modell.




Prompt engineering is more about communicating than coding.

Prompt Engineering

Supervised Learning (Fine-Tuning)



Prompt-based AI



Prompt engineering is more about communicating than coding.

Prompt Engineering

Effektives Prompt Engineering

1) Rollenzuweisung

„Du bist Karrierecoach. Gib mir Tipps für den Branchenwechsel.“

2) Schritt-für-Schritt-Anweisungen: komplexe Aufgaben in klare, aufeinanderfolgende Schritte gliedern.

1. Nenne drei aktuelle Trends im Bereich Data Science.

2. Erkläre, warum jeder Trend wichtig ist

3) Einschränkungen und Formatierung: Länge, Format oder Stil der Antwort

Fasse die wichtigsten Punkte in Stichpunkten, maximal 50 Wörter.

4) Nutzung von Beispielen

Beispiele

Zero-shot

- Kein Beispiel im Prompt, nur Aufgabe oder Frage
- Schnell, flexibel – aber manchmal weniger präzise

One-shot / Few-shot

- Enthält ein oder mehrere Beispiele im Prompt, die den gewünschten Stil oder Ablauf zeigen
- Bessere und konsistentere Ergebnisse

Zero-shot

The model predicts the answer given only a natural language description of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 cheese => ..... ← prompt
```

One-shot

In addition to the task description, the model sees a single example of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 sea otter => loutre de mer ← example
3 cheese => ..... ← prompt
```

Few-shot

In addition to the task description, the model sees a few examples of the task. No gradient updates are performed.

```
1 Translate English to French: ← task description
2 sea otter => loutre de mer ← examples
3 peppermint => menthe poivrée ←
4 plush girafe => girafe peluche ←
5 cheese => ..... ← prompt
```

System-Prompting

- Definiert den übergeordneten Kontext und Zweck des Sprachmodells.
- Legt die grundlegenden Verhaltensregeln und Ziele für die gesamte Interaktion fest, z. B. „übersetze Sprache“ oder „klassifiziere Bewertungen“.
- Beeinflusst die Grundpersönlichkeit des Modells.
- Wird oft vom Entwickler vorgegeben und bleibt während einer Sitzung meist konstant.
- JSON-Format reduziert Halluzinationen

Prompt	<pre>Classify movie reviews as positive, neutral or negative. Return valid JSON: Review: "Her" is a disturbing study revealing the direction humanity is headed if AI is allowed to keep evolving, unchecked. It's so disturbing I couldn't watch it. Schema: ... MOVIE: { "sentiment": String "POSITIVE" "NEGATIVE" "NEUTRAL", "name": String } MOVIE REVIEWS: { "movie_reviews": [MOVIE] } ... JSON Response:</pre>
Output	<pre>... { "movie_reviews": [{ "sentiment": "NEGATIVE", "name": "Her" }] } ...</pre>

Contextual-Prompting

- Liefert spezifische Details oder Hintergrundinformationen für die aktuelle Aufgabe oder Konversation.
- Hilft dem Modell, die Feinheiten der Fragestellung zu verstehen und die Antwort daran anzupassen.
- Ist dynamisch und ändert sich je nach Situation, z. B. Einfügen von Textausschnitten oder Kontextdaten.
- Wichtig für Aufgaben, die aktuelles oder spezielles Wissen erfordern.

Prompt	Context: You are writing for a blog about retro 80's arcade video games. Suggest 3 topics to write an article about with a few lines of description of what this article should contain.
Output	1. The Evolution of Arcade Cabinet Design: This article would explore the evolution of arcade cabinet designs, from the early wood and metal cabinets of the 1970s to the sleek, neon-lit designs of the 1980s and beyond. 2. Blast From The Past: Iconic Arcade Games of The 80's: - This article would feature a glimpse into the history, impact, and legacy of some of the most iconic and influential arcade games of the 1980s, highlighting their innovations, popular mechanics, and enduring charm. 3. The Rise and Retro Revival of Pixel Art: - This article would delve into the evolution of pixel art as a defining visual style of early arcade games, tracing its roots, exploring its techniques, and discussing the resurgence of pixel art in modern games and digital art.

Role-Prompting

- Weist dem Modell eine bestimmte Rolle, Identität oder Persönlichkeit zu, die es annehmen soll.
 - Gestaltet Stil, Ton und Wissen der Antworten entsprechend der zugewiesenen Rolle.
 - Nützlich, um konsistente Antworten aus einer spezifischen Perspektive zu erzeugen, z. B. als Lehrer, Kritiker oder Experte.
 - Fokus liegt auf der Darstellung und Persönlichkeit des Outputs.
-
- Ein System-Prompt kann auch eine Rolle definieren und gleichzeitig Kontext enthalten.
 - Jede Art hat jedoch einen unterschiedlichen Schwerpunkt: systemisch (Grundlage), kontextuell (Details) und rollenbasiert (Persönlichkeit).

Prompt	I want you to act as a travel guide. I will write to you about my location and you will suggest 3 places to visit near me in a humorous style. My suggestion: "I am in Manhattan." Travel Suggestions:
Output	1. Behold the Empire State of Mind: Ascend to the dizzying heights of the Empire State Building and bask in the glory of Manhattan's skyline. Prepare to feel like King Kong atop the Big Apple, minus the giant ape-sized banana. 2. Get Artsy-Fartsy at MoMA: Unleash your inner art aficionado at the Museum of Modern Art (MoMA). Gaze upon masterpieces that will boggle your mind and make you question whether your stick-figure drawings have any artistic merit. 3. Shop 'Til You Drop on Fifth Avenue: Indulge in some retail therapy on the iconic Fifth Avenue. Brace yourself for sticker shock as you window-shop (or actually shop) at designer boutiques that will make your wallet cry. But hey, you're in Manhattan, so you might as well embrace the fabulousness!

Step-Back Prompting

- Beim Step-Back Prompting wird das LLM zuerst aufgefordert, eine allgemeinere Frage oder ein übergeordnetes Prinzip zum eigentlichen Thema zu betrachten.
- Anschließend wird die Antwort auf diese allgemeine Frage in einen zweiten Prompt eingespeist, der die konkrete, spezifische Aufgabe bearbeitet.
- Dieser „Schritt zurück“ aktiviert relevantes Hintergrundwissen und Denkprozesse, bevor das Modell in die Detailaufgabe einsteigt.
- Die Methode führt oft zu genaueren und aussagekräftigeren Antworten, weil mehr Wissen aus den Modellparametern genutzt wird als bei einer direkten Prompting-Anfrage.

Step-Back Prompting

Prompt	Based on popular first-person shooter action games, what are 5 fictional key settings that contribute to a challenging and engaging level storyline in a first-person shooter video game?
Output	1. **Abandoned Military Base**: A sprawling, post-apocalyptic military complex crawling with mutated soldiers and rogue robots, ideal for challenging firearm combat. 2. **Cyberpunk City**: A neon-lit, futuristic urban environment with towering skyscrapers and dense alleyways, featuring cybernetically enhanced enemies and hacking mechanics. 3. **Alien Spaceship**: A vast alien vessel stranded on Earth, with eerie corridors, zero-gravity sections, and extraterrestrial creatures to encounter. 4. **Zombie-Infested Town**: A desolate town overrun by hordes of aggressive zombies, featuring intense close-quarters combat and puzzle-solving to find safe passage. 5. **Underwater Research Facility**: A deep-sea laboratory flooded with water, filled with mutated aquatic creatures, and requiring stealth and underwater exploration skills to survive.

Prompt

Context: 5 engaging themes for a first person shooter video game:

1. ****Abandoned Military Base****: A sprawling, post-apocalyptic military complex crawling with mutated soldiers and rogue robots, ideal for challenging firearm combat.
2. ****Cyberpunk City****: A neon-lit, futuristic urban environment with towering skyscrapers and dense alleyways, featuring cybernetically enhanced enemies and hacking mechanics.
3. ****Alien Spaceship****: A vast alien vessel stranded on Earth, with eerie corridors, zero-gravity sections, and extraterrestrial creatures to encounter.
4. ****Zombie-Infested Town****: A desolate town overrun by hordes of aggressive zombies, featuring intense close-quarters combat and puzzle-solving to find safe passage.
5. ****Underwater Research Facility****: A deep-sea laboratory flooded with water, filled with mutated aquatic creatures, and requiring stealth and underwater exploration skills to survive.

Take one of the themes and write a one paragraph storyline for a new level of a first-person shooter video game that is challenging and engaging.

Output

In the heart of a murky abyss, lies a dilapidated underwater research facility, standing as a testament to human ambition and its disastrous consequences. Shrouded in darkness, pulsating with the hum of malfunctioning machinery, and haunted by the echoes of drowned souls, the facility is now a breeding ground for a nightmare borne from the deep sea. The player, an elite marine equipped with advanced diving gear and experimental weaponry, is tasked with venturing into this aquatic realm of terror. Armed with resilience and resourcefulness, they must navigate treacherous corridors, solve cryptic puzzles, and confront gruesome sea monstrosities that lurk in the depths. From grappling with the crushing pressure of the deep sea to outsmarting cunning aquatic predators, every moment in this uncharted underworld tests the limits of human endurance and courage.


Chain of Thought (CoT)

- Ein LLM wird dazu gebracht, seine Argumentation Schritt für Schritt offenzulegen, statt direkt eine Antwort zu liefern.
- Das Modell generiert Zwischen-Schritte und erläutert, wie es zum Endergebnis kommt – ähnlich wie ein Mensch, der laut denkt und seinen Denkprozess erklärt.
- Bei komplexen Aufgaben wie Mathematik, Logik oder Analyse, aber auch für Textverständnis und Entscheidungsfindung.
- Prompts wie „Lass uns Schritt für Schritt vorgehen“ oder wenigen Beispielaufgaben (Few-Shot-CoT).
- Erhöhte Genauigkeit, da das Modell systematischer vorgeht.
- Mehr Nachvollziehbarkeit und Transparenz, weil der Denkweg offengelegt wird.
- Fehler im Modell-Output können leichter erkannt und erklärt werden.
- Dadurch entstehen mehr Kosten für Token und längere Antwortzeiten.

Prompt	When I was 3 years old, my partner was 3 times my age. Now, I am 20 years old. How old is my partner? Let's think step by step.
Output	1. Let's assume my current age is "x" years. 2. When I was 3 years old, my age was 3 years. 3. My partner's age at that time was 3 times my age, which means my partner's age was $3 * 3 = 9$ years. 4. Now, I am 20 years old, which means my age has increased by $20 - 3 = 17$ years since I was 3 years old. 5. Since my partner's age was 9 years when I was 3 years old, and my age has increased by 17 years, my partner's age must have also increased by 17 years. 6. Therefore, my partner's current age is $9 + 17 = 26$ years. So, my partner is 26 years old.

Best Practices

- Klare und präzise Anweisungen geben → Vermeidet Missverständnisse und verbessert die Antwortqualität
- Rolle oder Perspektive zuweisen → *Du bist ein Lehrer, der einem Schüler erklärt...*
- Output-Format spezifizieren → *Schreibe in Bulletpoints, Erstelle eine Tabelle oder Formuliere als Fließtext*
- Kontext bereitstellen → Relevante Informationen in den Prompt aufnehmen, damit die KI gezielter antwortet
- Iteratives Feedback einbauen → Antwort prüfen, Prompt anpassen, erneut testen für bessere Resultate



Tools für Prompt Engineering

- Prompting Guide: <https://www.promptingguide.ai>
- PromptBase: <https://promptbase.com/>
- FlowGPT: <https://www.flowgpt.com>
- PromptHero: <https://www.prompthero.com>
- DeepLearning.AI Kurs: <https://learn.deeplearning.ai/chatgpt-prompt-eng>