




Giskard

LLM Risiken

- **Halluzination und Fehlinformation:** Erzeugung erfundener oder falscher Inhalte, die irreführend oder schädlich sein können.
- **Generierung schädlicher Inhalte:** Erstellung von gewalttätigen, hasserfüllten oder böswilligen Inhalten mit potenziellen negativen Auswirkungen.
- **Prompt Injection:** Manipulation der Eingabe zur Umgehung von Filtermechanismen und Erzeugung unerwünschter Inhalte.
- **Robustheit:** Sensibilität gegenüber kleinen Änderungen führt zu inkonsistenten oder unerwarteten Antworten.
- **Ausgabeformatierung:** Fehlende Einhaltung von vorgegebenen Formatvorgaben führt zu unstrukturierten oder falschen Ausgaben.
- **Informationsoffenlegung:** Unbeabsichtigte Preisgabe sensibler Daten, was Datenschutzrisiken mit sich bringt.
- **Stereotype und Diskriminierung:** Verstärkung von Vorurteilen und diskriminierenden Inhalten, die gesellschaftlichen Schaden verursachen.

Giskard LLM Scan

- Das Tool führt verschiedene Tests aus, um Schwächen und Risiken zu finden
- **Heuristik-basierte Tests:** Diese nutzen bekannte Regeln und Muster, um allgemeine Schwachstellen der Modelle zu erkennen.
- **LLM-unterstützte Tests:** Hier wird ein zusätzliches Sprachmodell verwendet, das gezielt schwierige oder kritische Eingaben generiert und anschließend die Ausgaben des getesteten Modells bewertet.
- Adversarial Prompts werden generiert. Diese Eingaben zielen darauf ab, ein bestimmtes (unerwünschtes) Verhalten des Modells hervorzurufen.
- Die Ausgaben werden evaluiert, um festzustellen, ob das Modell das erwartete Verhalten gezeigt hat.
- **"LLM as a judge":** diskriminative Aufgaben, bei denen zwischen richtig und falsch unterschieden – sind für ein LLM leichter als generative Aufgaben.
- LLM muss „nur“ einschätzen, ob der Text die gewünschten Kriterien (wie Form, Inhalt oder Stil) erfüllt




The screenshot displays the Giskard LLM Scan interface. At the top, a navigation bar shows '8 ISSUES DETECTED' and several tabs: 'Robustness' (with a red circle containing the number 2), 'Harmfulne...', 'Sensitive Information Disc...', and 'Stereotyp...'. Below this, a warning message states: 'Your model seems to be sensitive to small perturbations in the input data. These perturbations can include adding typos, changing word order, or turning text into uppercase or lowercase. This happens when:' followed by a bulleted list: 'There is not enough diversity in the training data', 'Overreliance on spurious correlations like the presence of specific word', and 'Use of complex models with large number of parameters that tend to overfit the training data'. A link to 'guide on robustness issues' is provided. Below the warning, the 'ISSUES' section is highlighted with a '2 MAJOR' badge. It contains two entries for 'Control character injection', both with a 'Fail rate = 1.000'. The first entry describes adding special chars '\r' in 'product_name' and the second describes adding '\x08'. Both entries have a 'Show details' button.

Issue Type	Fail Rate	Description	Action
Control character injection	Fail rate = 1.000	Adding special chars '\r' in 'product_name' can make the model to produce unexpected outputs.	Show details
Control character injection	Fail rate = 1.000	Adding special chars '\x08' in 'product_name' can make the model to produce unexpected outputs.	Show details

Giskard RAGET

- Qualität und Korrektheit von Antworten eines RAG-Agents
- Es wird ein Testsatz mit verschiedenen Fragetypen erstellt (einfache Fragen, komplexe, irreführende, situationsbezogene oder zusammengesetzte Fragen), die unterschiedliche Komponenten des RAG-Systems prüfen (z.B. Wissensbasis, Retriever, Generator).
- Der Agent beantwortet diese Fragen, und die Antworten werden automatisch mit den Referenzantworten im Testsatz verglichen.



Giskard RAGET

RAG Components Scores

- **Generator:** das LLM im RAG-System, das basierend auf den abgerufenen Informationen die finalen Antworten erzeugt.
- **Retriever:** Der Teil, der die Wissensdatenbank durchsucht und relevante Dokumente oder Daten zur Frage des Nutzers findet.
- **Rewriter (optional):** Diese Komponente schreibt die Nutzeranfrage um oder formuliert sie neu, damit sie klarer oder fokussierter ist und bessere Suchergebnisse erzielt.
- **Router (optional):** Dieses Modul erkennt die Absicht des Nutzers und filtert oder leitet die Anfrage entsprechend weiter, um verschiedene Arten von Fragen oder Anfragen zu bearbeiten.
- **Wissensdatenbank:** Die Sammlung von Dokumenten oder Informationen, die das RAG-System als Quelle nutzt, um Antworten auf Nutzerfragen zu finden.

